

Файловые системы





Дмитрий Яценко

Lead DevOps в Quadcode

План модуля

- 1. Работа в терминале, лекция 1
- 2. Работа в терминале, лекция 2
- 3. Операционные системы, лекция 1
- 4. Операционные системы, лекция 2
- 5. Файловые системы
- 6. Компьютерные сети, лекция 1
- 7. Компьютерные сети, лекция 2
- 8. Компьютерные сети, лекция 3
- 9. Элементы безопасности информационных систем

План занятия

- 1. Объекты файловой системы
- 2. Права доступа
- 3. <u>Организация хранения данных в Linux</u>
- 4. RAID/mdadm
- 5. <u>LVM2</u>
- 6. Таблица разделов
- 7. Создание и монтирование файловых систем
- 8. <u>Итоги</u>
- 9. Домашнее задание

Объекты файловой системы

file

Что такое файл?

Специально организованная структура данных, распознаваемая компьютером как единое целое.

Oxford Languages

man 2 stat, /stat \{

Некоторые важные поля объектов файловой системы:

```
struct stat {
    dev_t st_dev; /* ID устройства, содержащего файл */
    ino_t st_ino; /* номер Inode */
    mode_t st_mode; /* биты доступа + тип файла */
    nlink_t st_nlink; /* число hard links (жестких ссылок) */
    uid_t st_uid; /* User ID - принадлежность пользователю */
    gid_t st_gid; /* Group ID - принадлежность группе */
    dev_t st_rdev;

/* Device ID - тип устройства, если файл является
    файлом специального назначения */
        off_t st_size; /* Размер в байтах */
        struct timespec st_atim; /* Время последнего доступа */
        struct timespec st_mtim; /* Время последнего изменения содержимого */
        struct timespec st_ctim; /* Время последнего изменения метаданных */
        ...
```

Уже по структуре данных системного вызова **stat** мы видим, что файл это не обязательно область на диске с данными. Например, файл может представлять устройство.

timespec – не всегда времена доступа честно обновляются из соображений производительности (опции монтирования).

Команда stat

- важнейшее поле **Inode** (индексный дескриптор)
- тип файла: regular file (обычный файл)
- 1 жесткая ссылка на объект (поле **Links**)
- Uid принадлежность пользователю, Gid принадлежность группе

IO Block – размер блока на файловой системе

```
root@netology1:~# tune2fs -l /dev/mapper/vgvagrant-root | grep 'Block size'
Block size: 4096
```

8 Blocks – размер физического блока устройства:

```
root@netology1:~# cat /sys/block/sda/queue/physical_block_size
512
```

Поэтому, даже при малом размере файла в 198 байт на устройстве выделено 8 блоков по 512 байт (так как минимальный блок ФС – 4096 байт).

inode - индексный дескриптор

Уникальный *в рамках файловой системы* контейнер метаданных файла (пара inode+device – однозначный *идентификатор объекта в системе*).

stat читает данные из inode.

inode – первичный идентификатор объекта на файловой системе.

Имя таковым не является: в рамках одной ФС может быть создано более одного файла с одним и тем же inode и разными именами: число таких ссылок и показывает stat в поле Links. У обычного файла будет только одна ссылка. Создадим более одной ссылки:

```
root@netology1:~# touch test_file
root@netology1:~# stat --format=%h test_file
1
root@netology1:~# ln test_file this_is_hardlink_for_test_file
root@netology1:~# stat --format=%h test_file
2
root@netology1:~# stat --format=%i test_file; stat --format=%i
this_is_hardlink_for_test_file
1179657
1179657
```

Если мы удалим оригинальный test_file, объект продолжит существование на ФС, так как на него будет присутствовать ссылка this_is_hardlink_for_test_file:

```
root@netology1:~# rm test_file
root@netology1:~# stat --format=%h,%i this_is_hardlink_for_test_file
1,1179657
```

inode, имена файлов

- Имена файлов и соответствие имен<>inode хранятся в структуре директории, в которой эти файлы находятся.
- Число inode определяет число объектов, которое может быть создано на ФС.
- Есть ФС, где inode предварительно выделяются при создании (семейство **ext**); есть те, где inode может быть добавлены динамически (**xfs**). Об этом важно знать, так как может сложиться ситуация, при которой на ФС есть свободное пространство для создания файлов, но уже нет inode (слишком много файлов).

Одна из встречающихся техник программирования в Linux – изменения поведения программы в зависимости от того, под каким именем ее вызвали.

```
root@netology1:~# ls -li /usr/bin/bzip2
3407895 -rwxr-xr-x 3 root root 39144 Sep 5 2019 /usr/bin/bzip2
root@netology1:~# find /usr/bin -inum 3407895
/usr/bin/bunzip2
/usr/bin/bzip2
/usr/bin/bzcat
```



В каких объектах файловой системы присутствует больше одной жесткой ссылки?

dentry (directory entry), директории

Мы узнали, что название файла – запись об именовании inode в структуре, которая представляет директорию.

Эта структура называется **dentry**, когда мы просматриваем содержимое директорий ls, происходит системный вызов **getdents64**:

```
root@netology1:~# strace -e getdents64 ls
getdents64(3, /* 4 entries */, 32768) = 112
```

Так как у любой директории помимо своего имени присутствует и короткая ссылка (,), у директорий всегда не менее двух hardlink.

man 2 stat, /S_IFMT

В **man** по системному вызову **stat** описаны типы файлов, которые встречаются в Linux:

- regular file, стандартный файл;
- directory, директория;
- symlink родственная жесткой ссылке сущность. Встречаются названия мягкая ссылка и симлинк. В отличие от hardlink, symlink это полноценный объект на файловой системе, который, в частности, может переходить ее границы и ссылаться на объекты других ФС. Не увеличивает счетчик ссылок Links и не влияет на сохранность адреса ссылки (аналогия с ярлыком Windows) при удалении;
- **pipe** мы с вами уже встречались с пайпами, **I**, это неименованные пайпы.

```
vagrant@netology1:~$ mkfifo test_pipe
vagrant@netology1:~$ ls -l test_pipe
prw-rw-r-- 1 vagrant vagrant 0 Jul 12 19:03 test_pipe
vagrant@netology1:~$ echo Hello Netology > test_pipe &
vagrant@netology1:~$ cat test_pipe
Hello Netology
```

Типы файлов, socket

socket – бывает сетевым (для соединения удаленных хостов) и локальным (для соединения в рамках одного хоста). Сетевые рассмотрим в следующих лекциях. Локальные (доменные) сокеты – еще один тип межпроцессного взаимодействия (в дополнение к уже известным нам именованным и неименованным пайпам, сигналам и разделяемой памяти процессов). Если в сетевых для подключения сокета используется сетевой адрес+порт, в доменном сокете данным адресом является путь на файловой системе.

Плюсы перед ріре:

- сокеты могут быть двунаправленными, тогда как ріре однонаправленные,
- производительнее,
- много клиентов может писать в один ріре, однако сторона-приемник не может узнать, кто записал в ріре, в socket такой проблемы нет.

Пример: общение nginx c php-fpm через сокет:

```
root@netology1:~# grep '^listen ' /etc/php/7.4/fpm/pool.d/www.conf
listen = /run/php/php7.4-fpm.sock

root@netology1:~# grep fastcgi_pass /etc/nginx/sites-enabled/default
    fastcgi_pass unix:/run/php/php7.4-fpm.sock;

root@netology1:~# curl -s 'localhost:81' | grep 'PHP Version' | grep 'td class'
PHP Version 7.4.3
```

Символические ссылки

```
root@netology1:/usr/sbin# ls -l vgs* | head -n2
lrwxrwxrwx 1 root root 3 Feb 13 21:21 vgs -> lvm
lrwxrwxrwx 1 root root 3 Feb 13 21:21 vgscan -> lvm
```

Так ссылки отображаются на ФС. Они могут быть как относительными (в примере выше), так и абсолютными. symlink'и так же создаются командой ln, но с ключем -s:

```
vagrant@netology1:~$ touch test_file
vagrant@netology1:~$ ln -s $HOME/test_file test_link
vagrant@netology1:~$ ls -l ~/test_link
lrwxrwxrwx 1 vagrant vagrant 23 xxx 18:29 /home/vagrant/test_link ->
/home/vagrant/test_file
```

Права доступа

Стандартные права доступа

Биты разрешений:

- r read, чтение
- w write, запись
- x execution, исполнение

К кому применяются разрешения:

- владелец
- группа-владелец
- все пользователи

Итого, 9 бит стандартных атрибутов:

Владелец			Группа			Bce		
r	w	x	r	w	x	r	w	x
1	1	0	1	0	0	1	0	0

В десятичной записи:

$$r: 2^2 = 4$$
 $w: 2^1 = 2$ $x: 2^0 = 1$

Стандартные права доступа, применимость

Для файлов:

- read для просмотра содержимого файлов
- write для изменения содержимого файлов
- execute для запуска файла в качестве программы (процесса)

Для директорий:

- read для просмотра содержимого директории (ls)
- write для создания или удаления объектов из директории
- execute для chdir в директорию

Изменение владельца

chown – change owner, изменить владельца/группу:

```
root@netology1:/tmp# touch file
root@netology1:/tmp# chown vagrant file
root@netology1:/tmp# stat file | grep Uid
Access: (0644/-rw-r--r--) Uid: ( 1000/ vagrant) Gid: ( 0/ root)
```

С одинарным аргументом – меняет пользователя.

С аргументом вида : group – меняет группу.

```
root@netology1:/tmp# chown :vagrant file
root@netology1:/tmp# stat file | grep Uid
Access: (0644/-rw-r--r--) Uid: ( 1000/ vagrant) Gid: ( 1000/ vagrant)
```

При вызове вида user:, изменит и пользователя и группу (равнозначно user:user):

```
root@netology1:/tmp# touch file2
root@netology1:/tmp# chown vagrant: file2
root@netology1:/tmp# stat file2 | grep Uid
Access: (0644/-rw-r--r--) Uid: ( 1000/ vagrant) Gid: ( 1000/ vagrant)
```

Изменение прав доступа

chmod – change mode, изменить биты разрешений доступа.

```
С десятичной записью полных прав: chmod 0755 file, или с буквенной записью: chmod u=rwx,g=rx,o=rx file.
```

Можно добавлять (+) или убирать (-) относительно имеющихся:

```
root@netology1:/tmp# stat file | grep Uid
Access: (0755/-rwxr-xr-x) Uid: ( 1000/ vagrant) Gid: ( 1000/ vagrant)
root@netology1:/tmp# chmod a-x file
root@netology1:/tmp# stat file | grep Uid
Access: (0644/-rw-r--r--) Uid: ( 1000/ vagrant) Gid: ( 1000/ vagrant)
```

umask – user mask, пользовательская маска

Откуда берутся права доступа по умолчанию?

Для директорий штатные права ОС – 0777, для файлов – 0666. Тем не менее, применяя **mkdir** или **touch**, вы увидите:

```
vagrant@netology1:~$ mkdir dir; touch file
vagrant@netology1:~$ stat {dir,file} | grep Uid
Access: (0775/drwxrwxr-x) Uid: ( 1000/ vagrant) Gid: ( 1000/ vagrant)
Access: (0664/-rw-rw-r--) Uid: ( 1000/ vagrant) Gid: ( 1000/ vagrant)
```

Ответ: из них вычитается **umask** (0777 - 0002, 0666 - 0002):

```
vagrant@netology1:~$ umask
0002
```

Для привилегированного пользоваться значение umask иное – 0022.

Дополнительные права доступа

Полное поле атрибутов файла – 12 бит. Перед 9 битами пользовательских разрешений **есть еще три**:

- setuid
- setgid
- sticky

Логика установки такая же, как с rwx:

Не-пользовательские атрибуты				
setuid	setgid	sticky		
0	0	1		

В десятичной записи:

setuid:
$$2^2 = 4$$
 setgid: $2^1 = 2$ sticky: $2^0 = 1$

```
vagrant@netology1:~$ stat /tmp | grep Uid
Access: (1777/drwxrwxrwt) Uid: ( 0/ root) Gid: ( 0/ root)
```

Дополнительные права доступа, применимость

sticky бит используется для директорий, в которые доступна запись многим пользователям, но требуется защитить файлы от чужого вмешательства.

```
vagrant@netology1:~$ touch /tmp/vagrant_user_file
vagrant@netology1:~$ sudo -u www-data touch /tmp/www_data_user_file
vagrant@netology1:~$ ls -l /tmp/*_user_file
-rw-rw-r-- 1 vagrant vagrant 0 Jul 12 09:15 /tmp/vagrant_user_file
-rw-rw-r-- 1 www-data www-data 0 Jul 12 09:15 /tmp/www_data_user_file
vagrant@netology1:~$ rm /tmp/vagrant_user_file
vagrant@netology1:~$ rm /tmp/www_data_user_file
rm: remove write-protected regular empty file '/tmp/www_data_user_file'?
y
rm: cannot remove '/tmp/www_data_user_file': Operation not permitted
```

setuid / **setgid** имеют одинаковый механизм работы за исключением применимости к пользователю (U) или группе (G).

Обычно этот бит можно встретить *на исполняемых файлах*. Пользователь, запускающий такой файл, получает **процесс, работающий с правами владельца исполняемого файла** (а не своими собственными). Классический пример: вызов утилиты смены пароля passwd:

```
vagrant@netology1:~$ stat $(which passwd) | grep Uid
Access: (4755/-rwsr-xr-x) Uid: ( 0/ root) Gid: ( 0/ root)
```

Дополнительные права доступа (продолжение)

passwd требуется обновить файл /etc/shadow, в котором хранятся хеши паролей. Этот файл доступен на запись только root:

```
vagrant@netology1:~$ stat /etc/passwd | grep Uid
Access: (0644/-rw-r--r--) Uid: ( 0/ root) Gid: ( 0/ root)
```

suid бит на исполняемом файле passwd дает возможность запустить его с "эффективными" правами root даже обычному пользователю.

```
vagrant@netology1:~$ ps aux | grep passw[d]
root     242054  0.0  0.3  10464  3344 pts/1     S+  09:50  0:00 passwd
vagrant
vagrant@netology1:~$ grep Uid /proc/242054/status
Uid: 1000  0     0  # real, effective
vagrant@netology1:~$ id 0
uid=0(root) gid=0(root) groups=0(root)
vagrant@netology1:~$ id 1000
uid=1000(vagrant) gid=1000(vagrant)
```

Этот же пример показывает опасность некорректного употребления suid/guid, – если бы в passwd не было дополнительных проверок, любой пользователь мог бы поменять пароль root, чего, конечно же, сделать нельзя.

```
vagrant@netology1:~$ passwd root
passwd: You may not view or modify password information for root.
```

Дополнительные права доступа (продолжение)

setgid на директориях имеет другой эффект (setuid обычно не используется). С этим установленным битом вновь создаваемые файлы и директории наследуют группу владельца родительского каталога, а не пользователя, инициировавшего операцию.

```
vagrant@netology1:~$ mkdir test_dir
vagrant@netology1:~$ sudo chown :tcpdump test_dir
vagrant@netology1:~$ stat test_dir/ | grep Gid
Access: (0775/drwxrwxr-x) Uid: ( 1000/ vagrant) Gid: (65534/ nogroup)
```

Стандартное поведение без setgid:

```
vagrant@netology1:~$ mkdir test_dir/no_gid; stat $_ | grep Gid
Access: (0775/drwxrwxr-x) Uid: ( 1000/ vagrant) Gid: ( 1000/ vagrant)
```

Поведение с установленным setgid:

```
vagrant@netology1:~$ chmod g+s test_dir/
vagrant@netology1:~$ stat test_dir/ | grep Uid
Access: (2775/drwxrwsr-x) Uid: ( 1000/ vagrant) Gid: ( 114/ tcpdump)
vagrant@netology1:~$ mkdir test_dir/with_gid; stat $_ | grep Gid
Access: (2775/drwxrwsr-x) Uid: ( 1000/ vagrant) Gid: ( 114/ tcpdump)
```

Дополнительные атрибуты, Isattr/chattr

Помимо стандартных 12 бит для записи разрешений в метаданных файла, могут присутствовать дополнительный атрибуты, способные ввести в затруднение тех, кто о них не знает:

```
root@netology1:~# echo 'test' > test_file
-bash: test_file: Operation not permitted
root@netology1:~# stat test_file | grep Uid
Access: (0644/-rw-r--r--) Uid: ( 0/ root) Gid: ( 0/ root)
```

Почему root не может записать данные в файл, которым он владеет и имеет права на запись?

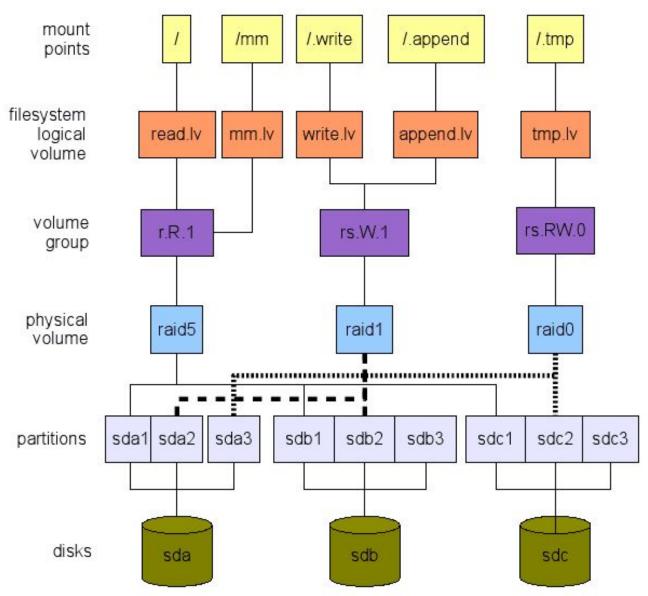
```
root@netology1:~# lsattr test_file
----i----------- test_file
```

Установлен флаг i – immutable, неизменяемый. Полный список расширенных атрибутов – man chattr, chattr – i для удаления immutable:

```
root@netology1:~# chattr -i test_file
root@netology1:~# echo 'test' > test_file
root@netology1:~# echo $?
0
```

Организация хранения данных в Linux

Схема уровней хранения данных



взято с сайта: <u>linuxconfig.org</u>

28

Базовые уровни хранения данных

• Блочное устройство (одиночный диск, RAID массив) – /dev/sda, /dev/nvme0n1:

```
:~# lsblk
NAME MAJ:MIN RM SIZE RO TYPE MOUNTPOINT
nvme2n1 259:2 0 8G 0 disk
```

Таблица разделов, раздел на блочном устройстве – /dev/sda1,
 /dev/nvme2n1p1:

```
nvme2n1 259:2 0 8G 0 disk

—nvme2n1p1 259:3 0 8G 0 part /
```

• Файловая система на разделе:

```
/dev/nvme2n1p1 on / type ext4 (rw,relatime,discard)
```

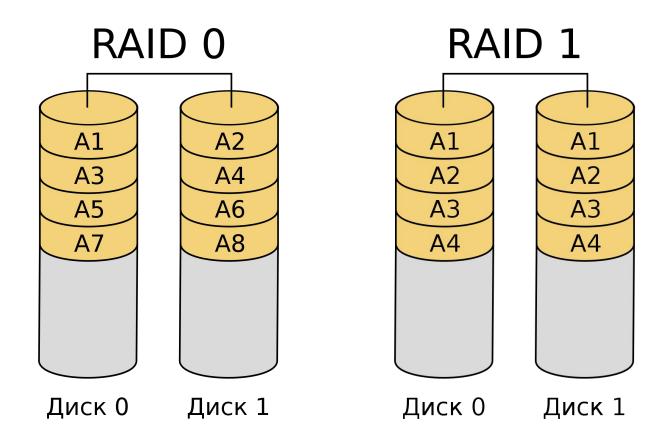
Большая гибкость ОС позволяет добавлять или заменять уровни: например, вместо создания таблицы разделов непосредственно на физическом блочном устройстве, можно использовать менеджер логических томов LVM2, и размещать файловую систему на его томах.

Или же, таблицу разделов можно не использовать вовсе, разместив ФС напрямую на блочном устройстве.

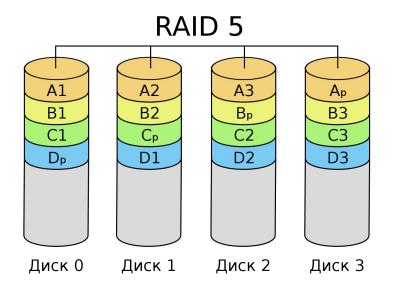
RAID/mdadm

RAIDO, RAID1

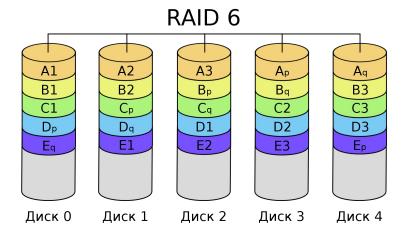
RAID – **R**edundant **A**rray of **I**ndependent **D**isks, избыточный массив независимых дисков.



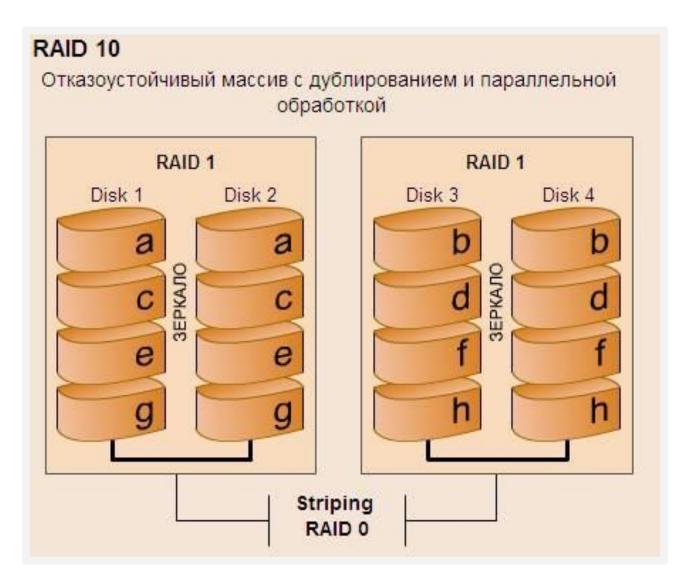
RAID5, RAID6



Α	В	A XOR B
0	0	0
0	1	1
1	0	1
1	1	0



RAID10 (1+0)



mdadm на примере RAIDO Amazon EBS

EC2 инстанс с 2 SSD дисками по 5 Гб каждый:

```
      nvme0n1
      259:0
      0
      5G
      0 disk

      nvme1n1
      259:1
      0
      5G
      0 disk
```

Создаем файловую систему на одиночном диске и тестируем производительность случайной записи:

```
mkfs.ext4 /dev/nvme1n1
mkdir /nvme_mount
mount /dev/nvme1n1 /nvme_mount
cd /nvme_mount; fio --name=randwrite --ioengine=libaio --iodepth=1 --rw=randwrite
--bs=4k --direct=0 --size=512M --numjobs=2 --runtime=60 --group_reporting
```

Результат:

```
WRITE: bw=9873KiB/s (10.1MB/s), 9873KiB/s-9873KiB/s (10.1MB/s-10.1MB/s), io=427MiB (448MB), run=44280-44280msec
```

Если вы посмотрите документацию, обнаружите, что без существенного увеличения размера диска (а, значит, и стоимости), получить больше производительности <u>не получится</u>. **На помощь придет mdadm**:

```
mdadm --create --verbose /dev/md0 --level=0 --raid-devices=2 /dev/nvme1n1 /dev/nvme2n1 WRITE: bw=19.9MiB/s (20.8MB/s), 19.9MiB/s-19.9MiB/s (20.8MB/s-20.8MB/s), io=1024MiB (1074MB), run=51507-51507msec
```

Статус mdadm

Искусственно пометим один из дисков сбойным:

mdadm.conf

```
root@vagrant:~# egrep '(DEVICE|initram)' /etc/mdadm/mdadm.conf
# !NB! Run update-initramfs -u after updating this file.
# !NB! This will ensure that initramfs has an uptodate copy.
#DEVICE partitions containers
```

Воспользуемся инструкцией для сохранения конфигурации:

```
root@vagrant:~# echo 'DEVICE partitions containers' > /etc/mdadm/mdadm.conf
root@vagrant:~# mdadm --detail --scan >> /etc/mdadm/mdadm.conf

root@vagrant:~# cat /etc/mdadm/mdadm.conf
DEVICE partitions containers
DEVICE partitions containers
ARRAY /dev/md0 metadata=1.2 name=vagrant:0
UUID=0e10b2a4:4b4a20e3:f3b7cc8d:a16a3425

root@vagrant:~# update-initramfs -u
update-initramfs: Generating /boot/initrd.img
```

Проверим после перезагрузки:

```
root@vagrant:~# mkdir /mountpoint
root@vagrant:~# blkid | grep md0
/dev/md0: UUID="9555ea98-78f3-4726-86c1-f9bd25916a12" TYPE="ext4"
root@vagrant:~# echo 'UUID=9555ea98-78f3-4726-86c1-f9bd25916a12 /mountpoint
ext4 errors=remount-ro 0 1' >> /etc/fstab; reboot
```

LVM2

Концепции менеджера логических томов

- физические тома Physical Volumes, pvdisplay/pvcreate/pvmove/...
 - (обычно размещаются на блочных устройствах)
- Физические тома объединяются в группы томов Volume Groups,
 vgdisplay/vgcreate/...
- VG служат пулом для логических томов Logical Volumes, lvdisplay/lvcreate/lvremove/...

```
root@netology1:~# pvs
     VG Fmt Attr PSize PFree
 PV
 /dev/sda5 vgvagrant lvm2 a-- <63.50g
root@netology1:~# vqs
 VG
    #PV #LV #SN Attr VSize
 vgvagrant 1 2 0 wz--n- <63.50g
root@netology1:~# lvdisplay /dev/vgvagrant/root
 --- Logical volume ---
                      /dev/vqvagrant/root
 LV Path
 LV Name
                      root
 VG Name
                      vgvagrant
                      0v7tWH-gBt5-oNrf-MTrG-iCme-ipGm-BAf0EU
 LV UUID
```

Таблица разделов

Просмотр и копирование таблицы разделов

sfdisk также работает в интерактивном режиме для модификации таблицы разделов.

Для копирования таблицы разделов на другое устройство лучше воспользоваться **sfdisk**:

```
:~# sfdisk -d /dev/nvme2n1
label: dos
label-id: 0xb93804ca
device: /dev/nvme2n1
unit: sectors
/dev/nvme2n1p1 : start= 2048, size= 16775135, type=83, bootable
:~# sfdisk -d /dev/nvme2n1 | sfdisk <new_disk>
```

Создание и монтирование файловых систем

man 5 fstab

Сама по себе созданная на разделе, томе или устройстве файловая система не появится в ОС автоматически – ее необходимо смонтировать (примерно как назначит букву диска в Windows.)

```
vagrant@netology1:~$ grep -v ^# /etc/fstab | column -t
/dev/mapper/vgvagrant-root / ext4 errors=remount-ro
0 1
UUID=E4AD-0D53 /boot/efi vfat umask=0077
0 1
/dev/mapper/vgvagrant-swap_1 none swap sw
0 0
```

Для создания файловых систем: mkfs.<fs_name>, mkfs.ext4.

Итоги

- узнали о структурах файловой системы и типах устройств;
- поговорили об организации хранения данных в Linux;
- рассмотрели наиболее распространенные уровни RAID;
- посмотрели на практике реализацию mdadm;
- поработали с менеджером логических томов LVM2.

Домашнее задание

Давайте посмотрим ваше домашнее задание.

- Вопросы по домашней работе задавайте в чате мессенджера.
- Задачи можно сдавать по частям.
- Зачёт по домашней работе проставляется после того, как приняты все задачи.



Задавайте вопросы и пишите отзыв о лекции!

Дмитрий Яценко