нетология

Программирование на Bash: **Regexp и их использование для синтаксического анализа. Полезные утилиты.**

Шило
Петр

Шило Петр

DevOps-инженер

Apifonica

Шило Петр

Предисловие

На этом занятии мы поговорим о:

- регулярных выражениях;
- таких утилитах как sed, awk, grep;
- работе с логами в Linux.

По итогу занятия вы получите представление о работе regex и научитесь использовать их для анализа информации.

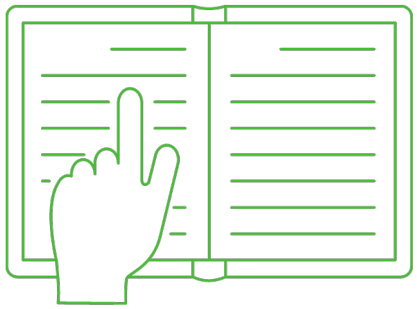

План занятия

1. Предисловие
2. Регулярные выражения
3. grep, sed
4. awk
5. Итоги
6. Домашнее задание

Регулярные выражения

Проблематика

Некоторые люди, сталкиваясь с проблемой, думают:

«Я знаю, я буду использовать регулярные выражения».

Теперь у них две проблемы.

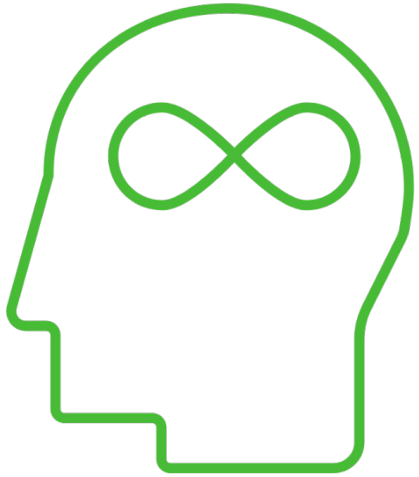

Обзор

Regex (Regular expression) – формальный язык поиска и осуществления манипуляций с подстроками в тексте.

Может использоваться для поиска и для замены данных в тексте.

Утилиты, поддерживающие регулярные выражения:

bash

grep

sed

awk

...

Пример регулярного выражения:

[A-Z0-9._%+-]+@[A-Z0-9.-]+\.[A-Z]{2,4}

Синтаксис

В регулярных выражениях используются свои метасимволы.

Вот основной их список.

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

В регулярных выражениях используются свои метасимволы.

Вот основной их список.

Использование регулярных выражений в grep.

grep -e 'regexp' filename

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

. (точка) соответствует любому символу.

Пример:

tes.

Соответствие:

test testttttt 1tes1 ratesk

Несоответствие:

tes vest

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

[] в скобках перечисляются символы которые необходимо искать.

Пример:

tes[tl]

Соответствие:

test testttttt tesla

Несоответствие:

tes vest tesk

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

Возможно также использовать диапазон. Заглавные и строчные символы указываются отдельными диапазонами.

Пример:

tes[a-z]

Соответствие:

test testttttt tesla tesz

Несоответствие:

tes vest tesA 0tes0

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

Аналогично предыдущему пункту но с инверсией.

Пример:

tes[^t]

Соответствие:

tesл tesa tesla tesz

Несоответствие:

tester test

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

Звездочка – любое количество символов.

Пример:

test*

Соответствие:

test tesa testttta tesz

Несоответствие:

est

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

Можно комбинировать с другими выражениями.

Пример:

.*

Соответствие:

Все

Несоответствие:

-

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

Можно комбинировать с другими выражениями.

Пример:

ab[cd]*

Соответствие:

abcccdddcdcddd ab

Несоответствие:

af

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

Один или более символов или выражений.

Пример:

ab1+

Соответствие:

ab111 ab1

Несоответствие:

ab

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Синтаксис

Ноль или один символ или выражение.

Пример:

ab1?

Соответствие:

ab1 ab

Несоответствие:

ab11 ab2 abc

.	любой символ;
[ ]	диапазон символов;
[^]	все символы, кроме указанных в фигурных скобках;
*	любое количество символов перед звездочкой, в том числе ноль;
+	одно или несколько стоящее перед ним выражение;
?	ноль или одно стоящее перед ним выражение;

Квантификаторы

Квантификатор – указатель количества предшествующих выражений или символов.

Символы * , + и ? также являются частными случаями квантификаторов.

* = {0,}

+ = {1,}

? = {0,1}

{n}	непосредственное количество;
{n,}	n или больше;
{n,m}	не меньше чем n и не больше чем m;
{,m}	не больше чем m;

Квантификаторы

Примеры:

wa[tr]{2}

{n}	непосредственное количество;
{n,}	n или больше;
{n,m}	не меньше чем n и не больше чем m;
{,m}	не больше чем m;

Квантификаторы

Примеры:

wa[tr]{2} = watt

tre{1,}

{n}	непосредственное количество;
{n,}	n или больше;
{n,m}	не меньше чем n и не больше чем m;
{,m}	не больше чем m;

Квантификаторы

Примеры:

wa[tr]{2} = watt

tre{1,} = tree

gab{0,1}[em]{1,3}

{n}	непосредственное количество;
{n,}	n или больше;
{n,m}	не меньше чем n и не больше чем m;
{,m}	не больше чем m;

Квантификаторы

Примеры:

wa[tr]{2} = watt

tre{1,} = tree

gab{0,1}[em]{1,3} = game

tol{,3}

{n}	непосредственное количество;
{n,}	n или больше;
{n,m}	не меньше чем n и не больше чем m;
{,m}	не больше чем m;

Квантификаторы

Примеры:

wa[tr]{2} = watt

tre{1,} = tree

gab{0,1}[em]{1,3} = game

tol{,3} = toll

{n}	непосредственное количество;
{n,}	n или больше;
{n,m}	не меньше чем n и не больше чем m;
{,m}	не больше чем m;

Экранирование и группировка

Для использования в регулярном выражении спецсимвола используется \

Сам \ экранируется как \\

Применить квантификатор к нескольким символам сразу можно использовав группировку: ( )

В качестве логического ИЛИ можно использовать |

Примеры:

(www.)?netology\.[a-z]{2,4}

(Moscow|Paris|London)+

grep, sed

grep

grep – утилита для поиска строк соответствующих регулярному выражению.

Типичное использование:

```
grep -e 'regexp' file
```

Из важных ключей:

- **-v** инвертирует вывод;
- **-c** подсчет количества выводимых строк вместо их вывода;
- **-n** вывод номера строки;
- **-i** нечувствительность к регистру;
- **-r** рекурсивный поиск по всем файлам.

Sed

sed (stream editor) – потоковый текстовый редактор.

Получает входящий поток (в виде файла) и редактирует его.

Типичное использование:

```
sed -e 's/abc/xyz/g' file > file2
```

Заменяет все строки abc на xyz в файле file и перенаправляет получившийся результат в file2

Sed

sed (stream editor) – потоковый текстовый редактор.

Получает входящий поток (в виде файла) и редактирует его.

Типичное использование:

sed -e 's/abc/xyz/g' file > file2

Заменяет все строки abc на xyz в файле file и перенаправляет получившийся результат в file2

Внимание, впереди опасность:

ключ **-i, --in-place.**

Производит замену в изначальном файле file.

Sed

Вместо файла можно использовать поток, например, из другой команды:

```
echo '123asd123' | sed 's/1/3/g'
ps aux | sed 's/.*root.*//g'
```

awk

Awk

Обладает практическими безграничными возможностями по обработке данных благодаря встроенному языку программирования.

Данные поступающие в awk можно представить в виде таблицы, где строки – это строки, а в качестве делителя столбцов выступает пробел.

Awk

Обладает практическими безграничными возможностями по обработке данных благодаря встроенному языку программирования.

Данные поступающие в awk можно представить в виде таблицы, где строки – это строки, а в качестве делителя столбцов выступает пробел.

Все столбцы заносятся в переменные:

$0 – вся строка целиком;

$1 – первый столбец;

$2 – второй столбец.

...

Чтобы использовать другой разделитель столбцов можно применить ключ **-F**

Например: -F:

Здесь стандартный разделитель заменен на **:**

Awk: синтаксис

Вывод чего либо на экран:

print ''

Объявление переменных:

var='value'

Условный оператор:

if-then-else

Цикл while:

while (i > 0){}

Awk: синтаксис

Вывод чего либо на экран:

print ''

Объявление переменных:

var='value'

Условный оператор:

if-then-else

Цикл while:

while (i > 0){}

Встроенные переменные:

- FS = разделитель столбцов;
- RS = разделитель строк;
- OFS = выходной разделитель столбцов;
- ORS = выходной разделитель строк.

Когда цикл перестает помещаться в одну строку то можно поместить его в файл и указать его имя ключом **-f**:

awk -f /tmp/awkscript

Awk: примеры

Вывод только нужных нам столбцов:

```
ps aux | awk '{print $2 $8}'
```

Вывод с условием:

```
ps aux | awk '{if ($2 > 200) print $2}'
```

Циклы внутри скрипта:

```
cat /proc/loadavg | awk '{i=1; sum=0; while (i<4){ sum += $i; i++ } print 'sum' }'
```

Работа с логами с помощью awk

1. Посмотрим сводную статистику по кодам ответа Nginx.

```
cat /var/log/nginx/access.log | awk '{print $9}' | sort -n | uniq -c
```

2. Запишем некоторый фрагмент сетевых логов в помощью tcpdump.

```
tcdump -n > tcpdump.txt
```

3. Посмотрим статистику по отправленным и принятым пакетам.

```
cat tcpdump.txt | awk '{a=gensub("\.[a-z0-9]+$","","g",$3);
b=gensub("\.[a-z0-9:]+$","","g",$5); print a $4 b}' | sort -n | uniq -c
```

Итоги

Итоги

Сегодня мы рассмотрели регулярные выражения и утилиты для работы с ними и теперь:

- умеем составлять регулярные выражения;
- можем применять их на практике.

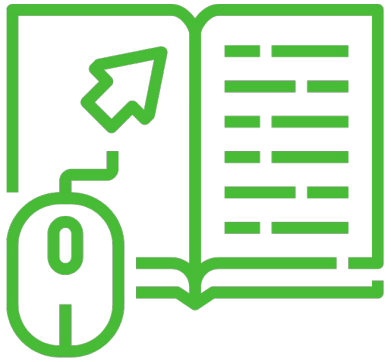

Домашнее задание

Домашнее задание

Давайте посмотрим ваше домашнее задание.

- Вопросы по домашней работе задавайте **в чате** мессенджера Slack.
- Задачи можно сдавать **по частям**.
- Зачёт по домашней работе проставляется после того, как **приняты все задачи**.

нетология

Задавайте вопросы и пишите отзыв о лекции!

Петр Шило

Петр Шило